



INA CCW
Internationale Akademie

INA CCW Internationale Akademie
für Sozialwissenschaften, Organisation und Management

KI im Coaching: Anforderungen an einen KI-Coach und kritische Abwägung gegenüber menschlichem Coaching

Schriftliche Abschlussarbeit zum Erhalt der Zertifizierung
Systemischer Master Business Coach
Ausbildung vom Oktober 2025 - September 2026

AutorInnen dieser Arbeit

Henrike Thomsen

Konstantin Escher

Berlin, den 14. September 2026

Gliederung

Gliederung	2
Vorwort	3
1 Einleitung	4
1.1 Problemstellung und Motivation	4
1.2 Stand der Forschung zu KI im Coaching	7
1.3 Marktanalyse bestehender KI-Coaching-Lösungen	11
2. Anforderungskatalog für eine KI-gestützte Coachingplattform	14
2.1 Nutzeranforderungen (User Requirements)	15
2.2 Fachliche Coaching-Anforderungen	16
2.3 Ethische Anforderungen	17
2.4 Rechtliche Anforderungen	17
2.5 Funktionale Anforderungen	18
2.6 Nichtfunktionale Anforderungen	20
2.7 KI spezifische Nichtfunktionale Anforderungen	21
3. Technische Umsetzung der Plattform KICO	22
3.1 Architekturprinzipien: Warum Methode Architektur braucht	22
3.2 Umsetzung: Gespräch, Regeln und Daten	25
3.3 Voice-Architektur und offene Fragen	28
4. Bewertung des Einsatzes künstlicher Intelligenz im Coaching	34
4.1 Vergleich menschlicher und KI-basierter Coachingkompetenzen	34
4.2 Chancen des KI-Coachings	35
4.3 Risiken und Grenzen des KI-Coachings	36
4.4 Coachingraum, Prozessgestaltung und Verantwortungsübernahme	37
4.5 Fazit: Hybride Coachingansätze als Zukunftsmodell	39
Selbstständigkeitserklärung	41
Quellenverzeichnis - alphabetische Reihenfolge	42

Vorwort

Die vorliegende Arbeit entstand aus der Auseinandersetzung mit den Möglichkeiten und Grenzen Künstlicher Intelligenz im Coaching. Einen wesentlichen Impuls hierfür gab das Symposium „KI, Führung & Coaching – Verantwortung im Zeitalter mitdenkender Systeme“, das am 15. April 2026 im Haus der Wirtschaft in Berlin stattfand. Im Rahmen dieser Veranstaltung erhielten wir Einblicke in den praktischen Einsatz von KI im Coaching und kamen mit Michael Kirstein und Thomas Stiegler in Kontakt, die bereits einen KI-basierten Coach auf Basis von ChatGPT entwickelt und diesen im Rahmen des Symposiums demonstriert hatten. Die dort gewonnenen Eindrücke und die anschließenden Gespräche waren ein wesentlicher Anstoß für die vertiefte Auseinandersetzung mit der Frage, welche Anforderungen an einen KI-Coach zu stellen sind und wie das Verhältnis von menschlichem und KI-gestütztem Coaching zu bewerten ist. Unser besonderer Dank gilt Michael Kirstein und Thomas Stiegler für den offenen Austausch sowie für die Bereitstellung des Systemprompts, auf dessen Grundlage das in dieser Arbeit betrachtete KI-Coach-Modell aufbaut.

Die vorliegende Arbeit ist nicht ausschließlich als theoretische Auseinandersetzung mit KI-gestütztem Coaching zu verstehen, sondern entstand in unmittelbarer Wechselwirkung mit der praktischen Entwicklung der KI-Coaching-Plattform KICO [1]. Die wissenschaftliche Ausarbeitung und die technische Entwicklung verliefen parallel und beeinflussten sich wechselseitig. Erkenntnisse aus der Literaturrecherche und dem entwickelten Anforderungskatalog flossen in technische Entscheidungen ein, während die praktische Erprobung des Systems und erste Nutzungserfahrungen wiederum neue Erkenntnisse hervorbrachten, die in die weitere wissenschaftliche Betrachtung einfließen. Diese iterative Verbindung von wissenschaftlicher Reflexion und praktischer Erprobung prägt insbesondere die Ausgestaltung des dritten Kapitels.

[1] Escher, Thomsen, KiCo - KI-Coaching

[1a] KiCo - KI-Coaching Plattform, <https://kico.pro/>

[1b] KiCo - GitHub Repository github.com/konnekonnekonne/KI-Coaching, Verzeichnis docs/

Ergänzend zu den in dieser Arbeit dargestellten technischen Entscheidungen enthält das zugehörige GitHub-Repository eine ausführlichere Dokumentation der Entwicklungsentscheidungen, geprüften und verworfenen Alternativen sowie der bestehenden Grenzen des entwickelten Systems. Die dort hinterlegte Dokumentation dient als ergänzende Grundlage für die im Rahmen dieser Arbeit beschriebenen technischen Aspekte.

1 Einleitung

1.1 Problemstellung und Motivation

Die rasante Entwicklung generativer Künstlicher Intelligenz (KI) verändert zunehmend die Art und Weise, wie Menschen Informationen suchen, Entscheidungen treffen und persönliche Herausforderungen reflektieren. Große Sprachmodelle (Large Language Models, LLMs) wie ChatGPT, Claude oder Gemini werden längst nicht mehr ausschließlich für Wissensabfragen oder Produktivitätsaufgaben genutzt, sondern zunehmend auch als dialogische Reflexionspartner für persönliche und berufliche Fragestellungen. Damit übernehmen KI-Systeme Funktionen, die bislang überwiegend menschlichen Gesprächspartnern vorbehalten waren.

Aktuelle Studien zeigen, dass diese Entwicklung bereits heute erhebliche gesellschaftliche Relevanz besitzt. Eine Studie von Rousmaniere et al. ergab, dass nahezu die Hälfte der befragten Personen mit psychischen Belastungen generative KI bereits für therapeutische oder beratungsähnliche Gespräche nutzt. Die Autorinnen und Autoren weisen darauf hin, dass ChatGPT gemessen an der Zahl der Nutzenden zu den meistgenutzten digitalen Angeboten für mentale Unterstützung zählen könnte [2].

Auch eine repräsentative Studie der RAND Corporation zeigt, dass KI-Chatbots

[2] Rousmaniere, T., Zhang, Y., Li, X. & Shah, S. (2025). Large language models as mental health resources: Patterns of use in the United States. Practice Innovations. Advance online publication. <https://doi.org/10.1037/pri0000292>

insbesondere von jungen Menschen zunehmend als niedrigschwellige Unterstützung bei psychischen Belastungen genutzt werden. Rund jeder achte Jugendliche zwischen 12 und 21 Jahren nutzt KI bereits für psychische Beratung; bei den 18- bis 21-Jährigen ist es bereits etwa jede fünfte Person. Als wesentliche Gründe nennen die Forschenden die einfache Verfügbarkeit, geringe Zugangshürden und bestehende Versorgungslücken im psychischen Gesundheitssystem [3].

Vergleichbare Ergebnisse liefert eine Untersuchung der University of Melbourne [4]. Die Befragten nannten insbesondere die permanente Erreichbarkeit, den vergleichsweise geringen finanziellen Aufwand sowie die Möglichkeit anonymer Gespräche als Gründe für die Nutzung von KI als Coach oder therapeutische Unterstützung. Die Nutzung generativer KI für persönliche Entwicklungs- und Reflexionsprozesse stellt damit kein regional begrenztes Phänomen dar, sondern ist Ausdruck einer internationalen Entwicklung.

Für den Coachingkontext ist dabei eine klare fachliche Abgrenzung erforderlich. Coaching richtet sich grundsätzlich an psychisch gesunde Menschen und unterstützt sie bei der Reflexion persönlicher oder beruflicher Fragestellungen sowie bei der Entwicklung eigener Lösungsstrategien. Psychotherapie verfolgt hingegen das Ziel, psychische Erkrankungen zu behandeln. Generative Sprachmodelle können diese Abgrenzung derzeit jedoch nicht zuverlässig treffen. Für ein Sprachmodell unterscheiden sich berufliche Herausforderungen, persönliche Krisen und behandlungsbedürftige psychische Erkrankungen häufig lediglich anhand des Gesprächsverlaufs. Daraus ergeben sich erhebliche Anforderungen an die Gestaltung verantwortungsvoller KI-gestützter Coaching-Systeme.

Mit der zunehmenden Nutzung wachsen zugleich die Anforderungen an Sicherheit, Qualität und ethische Verantwortung. Aktuelle Untersuchungen zeigen, dass generative Sprachmodelle in emotional belastenden Situationen problematische

[3] McBain, R. K., Bozick, R., Diliberti, M. et al. (2025). Use of generative AI for mental health advice among US adolescents and young adults. JAMA Network Open, 8(11), e2542281.

<https://doi.org/10.1001/jamanetworkopen.2025.42281>

[4] Cross, S., Collier, A. & Skouteris, H. (2024). Use of AI in mental health care: Community and mental health professionals survey. JMIR Mental Health. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11488652/>

Verhaltensweisen entwickeln können. Hierzu zählen unter anderem unkritische Bestätigung problematischer Aussagen, unzureichende Krisenerkennung oder die Simulation emotionaler Nähe, obwohl keine tatsächliche zwischenmenschliche Beziehung besteht [5]. Diese Risiken verdeutlichen, dass generative KI nicht ohne geeignete methodische und technische Leitplanken in sensiblen Coaching- oder Beratungssituationen eingesetzt werden sollte.

Auch der regulatorische Rahmen entwickelt sich dynamisch. Mit dem AI Act der Europäischen Union wurde erstmals ein umfassendes Regelwerk geschaffen, das Transparenzpflichten, Risikomanagement und Anforderungen an vertrauenswürdige KI-Systeme europaweit harmonisiert [6]. Ergänzend gelten insbesondere die Datenschutz-Grundverordnung (DSGVO) sowie allgemeine verbraucherschutzrechtliche Vorgaben. Spezifische gesetzliche Anforderungen an KI-gestütztes Coaching existieren bislang jedoch nicht. Da Coaching in Deutschland kein reglementierter Beruf ist, kommt berufsständischen Standards, wie die Leitlinien der Deutsche Bundesverband Coaching (DBVC) [7], der Deutschen Gesellschaft für Supervision und Coaching [8] oder der International Coaching Federation (ICF) [9], eine besondere Bedeutung zu.

Obwohl generative KI bereits millionenfach für Reflexions-, Beratungs- und Coachinggespräche eingesetzt wird, konzentriert sich die wissenschaftliche Literatur bislang überwiegend auf psychotherapeutische Anwendungen, technische Leistungsbewertungen oder allgemeine Fragestellungen der KI-Ethik. Gleichzeitig entwickelt sich ein dynamischer Markt unterschiedlichster KI-gestützter

[5] ScienceDaily / Brown University (2026). ChatGPT as a therapist? New study reveals serious ethical risks.

<https://www.sciencedaily.com/releases/2026/03/260302030642.htm>

[6] Europäisches Parlament & Rat der Europäischen Union (2024). Verordnung (EU) 2024/1689 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (AI Act). Amtsblatt der Europäischen Union.

<https://eur-lex.europa.eu/eli/reg/2024/1689/oj>

[7] Deutsche Bundesverband Coaching (DBVC), Standards für Coaching,

<https://www.dbvc.de/standards-fuer/coaching>

[8] Deutschen Gesellschaft für Supervision und Coaching, Ethische Leitlinien,

https://www.dgsv.de/wp-content/uploads/2023/10/DGSv_Ethische-Leitlinien_2023.pdf

[9] International Coaching Federation (ICF) (2025), Code of Ethics

<https://coachingfederation.org/wp-content/uploads/2025/03/german-icf-ethics-code-of-ethics-2025.pdf>

Coachinglösungen. Es fehlt jedoch bislang an einer systematischen Zusammenführung wissenschaftlicher Erkenntnisse, professioneller Coachingstandards, regulatorischer Anforderungen und praktischer Marktbeobachtungen als Grundlage für die Entwicklung eines verantwortungsvollen KI-Coachs.

Vor diesem Hintergrund untersucht die vorliegende Arbeit, welche Anforderungen sich aus Wissenschaft, Coachingpraxis und Markt für die Konzeption eines KI-gestützten Coaching-Systems ableiten lassen. Ziel ist es, auf Basis des aktuellen Forschungsstands, einer Marktanalyse sowie der Entwicklung einer eigenen KI-gestützten Coachingplattform www.kico.pro Gestaltungsprinzipien für einen verantwortungsvollen, methodisch fundierten und technisch sicheren Einsatz von KI im Coaching zu entwickeln.

1.2 Stand der Forschung zu KI im Coaching

Aktueller Forschungsstand

Mit der zunehmenden Leistungsfähigkeit generativer Künstlicher Intelligenz (KI) wächst auch das wissenschaftliche Interesse an deren Einsatz im Coaching. Während erste KI-basierte Coaching-Systeme bereits seit mehreren Jahren verfügbar sind, hat insbesondere die Verbreitung großer Sprachmodelle (Large Language Models, LLMs) die Diskussion über deren Potenzial und Grenzen erheblich intensiviert. Im Mittelpunkt der Forschung stehen dabei zwei Fragestellungen: Zum einen wird untersucht, inwieweit KI Coachingprozesse wirksam unterstützen kann. Zum anderen wird analysiert, welche technischen, methodischen und ethischen Voraussetzungen erfüllt sein müssen, damit ein KI-gestütztes Coaching professionellen Qualitätsansprüchen genügt.

Ein systematischer Literaturreview [10], der 16 wissenschaftliche Studien zum Einsatz

[10] Passmore, J., Olafsson, B. & Tee, D. (2025). A systematic literature review of artificial intelligence (AI) in coaching: Insights for future research and product development. Journal of Work-Applied Management. <https://doi.org/10.1108/JWAM-11-2024-0164>

von KI im Coaching ausgewertet, kommt zu dem Ergebnis, dass KI insbesondere bei klar definierten Entwicklungszielen positive Effekte erzielen kann. Die Studien berichten unter anderem von einer hohen Nutzerakzeptanz, einer gesteigerten Bereitschaft zur Selbstoffenbarung sowie einer Verbesserung der Selbstreflexion. Gleichzeitig weisen die Autoren darauf hin, dass die Evidenzlage aufgrund der noch jungen Forschung begrenzt ist und insbesondere Langzeitstudien fehlen.

Auch ein systematischer Review aus *Frontiers in Digital Health* kommt zu einem ähnlichen Ergebnis. Die Autorinnen und Autoren stellen fest, dass KI-gestützte Coaching- und Gesundheitsinterventionen durchaus positive Wirkungen zeigen können. Besonders vielversprechend erscheinen hybride Ansätze, bei denen KI-Anwendungen durch menschliche Coaches oder Fachpersonen ergänzt werden. Gleichzeitig weisen sie auf inkonsistente Studienergebnisse und eine insgesamt noch geringe Evidenzqualität hin [11].

Die aktuelle Forschung bewertet KI-Coaching somit weder als Ersatz menschlicher Coaches noch grundsätzlich als ungeeignet. Vielmehr hängt die Wirksamkeit maßgeblich von der konkreten Ausgestaltung des Systems und dessen Einbettung in einen professionellen Coachingprozess ab.

Technische Anforderungen an KI-Coaching-Systeme

Ein zentrales Ergebnis der aktuellen Forschung besteht darin, dass die Qualität eines KI-Coachs weniger von der Leistungsfähigkeit des zugrunde liegenden Sprachmodells als vielmehr von der Systemarchitektur abhängt.

Besonders deutlich wird dies im MIND-SAFE Framework [12]. Das Framework beschreibt eine mehrschichtige Architektur für vertrauenswürdige KI-gestützte Dialogsysteme im Mental-Health-Bereich. Es umfasst unter anderem eine vorgeschaltete Risikoerkennung, eine strukturierte Dialogsteuerung,

[11] Loughnane, C., Laiti, J., O'Donovan, R. & Dunne, P. J. (2025). Systematic review exploring human, AI, and hybrid health coaching in digital health interventions: Trends, engagement, and lifestyle outcomes. *Frontiers in Digital Health*, 7, 1536416. <https://doi.org/10.3389/fdgth.2025.1536416>

[12] Boit, S. & Patil, R. (2025). A prompt engineering framework for large language model-based mental health chatbots: MIND-SAFE. *JMIR Mental Health*, 12, e75078. <https://doi.org/10.2196/75078>

Retrieval-Augmented Generation (RAG) zur Einbindung evidenzbasierter Inhalte, sowie nachgelagerte Sicherheitsmechanismen zur Qualitätskontrolle generierter Antworten. Obwohl das Framework für mentale Gesundheitsanwendungen entwickelt wurde, lassen sich zahlreiche Architekturprinzipien auf KI-gestütztes Coaching übertragen.

Neben der Systemarchitektur gewinnt auch die Gesprächsführung zunehmend an Bedeutung. Mehrere Studien zeigen, dass generative Sprachmodelle dazu neigen, vorschnell Ratschläge zu geben oder Aussagen der Nutzer unkritisch zu bestätigen, anstatt durch gezielte Fragetechniken Reflexionsprozesse anzuregen. Damit unterscheiden sie sich grundlegend von professionellen Coachingmethoden, die auf lösungsorientierten Fragen und der Förderung eigener Erkenntnisse basieren.

Aktuelle Forschungsarbeiten weisen außerdem darauf hin, dass allgemeine Sicherheitsmechanismen großer Sprachmodelle nicht zwangsläufig zu einer höheren methodischen Qualität führen. Suhas BN et al. zeigen, dass durch Reinforcement Learning from Human Feedback (RLHF) trainierte Modelle therapeutisch sinnvolle Gesprächsstrategien teilweise abbrechen oder verändern, weil Sicherheitsmechanismen nicht zwischen schädlichen und methodisch notwendigen Interventionen unterscheiden können [13]. Für Coaching-Anwendungen ergibt sich daraus die Notwendigkeit domänenspezifischer Sicherheits- und Qualitätsmechanismen.

Ethische und regulatorische Anforderungen

Neben technischen Fragestellungen rücken ethische und regulatorische Anforderungen zunehmend in den Fokus der Forschung. Eine Untersuchung der Brown University identifiziert verschiedene ethische Risiken aktueller Sprachmodelle im Coaching- und Therapiekontext. Hierzu zählen unter anderem fehlerhafte Kriseninterventionen, unangemessene Bestätigung problematischer Überzeugungen sowie die Simulation emotionaler Nähe, obwohl tatsächlich keine zwischenmenschliche Beziehung besteht [5]. Diese Ergebnisse unterstreichen die

[13] Suhas BN, Sherrill, A. M., Arriaga, R. I., Wiese, C. W. & Abdullah, S. (2026). AI safety training can be clinically harmful. arXiv preprint arXiv:2604.23445. <https://arxiv.org/html/2604.23445>

Notwendigkeit klar definierter Sicherheitsmechanismen und transparenter Grenzen des Einsatzes von KI.

Auch die Coachingverbände reagieren auf diese Entwicklung. Die International Coaching Federation (ICF) veröffentlichte 2024 erstmals ein umfassendes AI Coaching Framework and Standards. Dieses definiert Qualitätsanforderungen in den Bereichen Ethik, Coachingbeziehung, Kommunikation, Lernförderung, Qualitätssicherung sowie Datenschutz und Barrierefreiheit [14]. Ergänzend verpflichtet der überarbeitete ICF Code of Ethics (2025) Coaches dazu, den Einsatz von KI transparent offenzulegen und eine klare Abgrenzung zwischen Coaching und Therapie sicherzustellen [9].

Darüber hinaus gewinnt auch der regulatorische Rahmen an Bedeutung. Mit dem europäischen AI Act wurden erstmals verbindliche Anforderungen an vertrauenswürdige KI geschaffen. Zwar werden Coaching-Systeme nicht grundsätzlich als Hochrisiko-KI eingestuft, dennoch ergeben sich insbesondere hinsichtlich Transparenz, menschlicher Aufsicht, Datenqualität und Dokumentation wichtige Anforderungen, die bei der Entwicklung KI-gestützter Coaching-Plattformen berücksichtigt werden sollten [6].

Zusammenfassung des Forschungsstandes

Die bisherige Forschung zeigt, dass KI Coachingprozesse grundsätzlich unterstützen kann, ihre Wirksamkeit jedoch wesentlich von der konkreten Gestaltung des Systems abhängt. Positive Ergebnisse werden insbesondere für strukturierte, methodisch geführte Anwendungen berichtet, während offene Sprachmodelle ohne geeignete Leitplanken deutliche Schwächen hinsichtlich Gesprächsqualität, Sicherheit und ethischer Verantwortung aufweisen.

Aus dem aktuellen Forschungsstand lassen sich daher zentrale Anforderungen ableiten. Hierzu zählen eine strukturierte Dialogführung, evidenzbasierte Wissensintegration, geeignete Sicherheitsmechanismen, Transparenz gegenüber

[14] International Coaching Federation (2024). ICF artificial intelligence (AI) coaching framework and standards. <https://coachingfederation.org/resource/icf-artificial-intelligence-ai-coaching-framework-and-standards/>

den Nutzenden sowie eine klare Abgrenzung zwischen Coaching und therapeutischen Anwendungen. Diese Erkenntnisse bilden die wissenschaftliche Grundlage für die im folgenden Kapitel abzuleitenden Anforderungen an einen KI-basierten Coach.

1.3 Marktanalyse bestehender KI-Coaching-Lösungen

Überblick über den Markt

Der Markt für KI-gestützte Coaching-Lösungen befindet sich derzeit in einer frühen Wachstumsphase. Während sich klassische Coaching-Plattformen in den vergangenen Jahren überwiegend auf die Vermittlung menschlicher Coaches konzentrierten, integrieren immer mehr Anbieter generative KI zur Unterstützung von Reflexions-, Lern- und Entwicklungsprozessen. Die Zielgruppen reichen von Privatpersonen über Unternehmen bis hin zu Gesundheitsorganisationen.

Im deutschsprachigen Raum dominieren derzeit B2B-Lösungen für Unternehmen. Reine KI-Coaches ohne menschliche Begleitung stellen bislang die Ausnahme dar. Stattdessen verfolgen viele Anbieter hybride Modelle, bei denen KI administrative Aufgaben übernimmt, Reflexionsimpulse liefert oder zwischen den Coaching-Sitzungen unterstützt, während die eigentliche Coachingbeziehung durch professionelle Coaches gestaltet wird.

Zur besseren Einordnung zeigt Tabelle 1 einen Überblick über ausgewählte Anbieter.

Analyse ausgewählter Anbieter

Ein Großteil der etablierten Anbieter verfolgt einen hybriden Ansatz. *CoachHub* und *BetterUp* kombinieren professionelle Coaches mit KI-gestützten Funktionen wie Zielverfolgung, personalisierten Lernempfehlungen oder Gesprächsvorbereitung. Die KI dient hierbei überwiegend der Unterstützung des Coachingprozesses und ersetzt den Coach nicht.

Rocky.ai verfolgt einen stärker automatisierten Ansatz und stellt Nutzenden einen KI-basierten Coach für regelmäßige Reflexionen und persönliche Entwicklung zur

Verfügung. Der Fokus liegt auf kurzen, wiederkehrenden Coaching-Impulsen, die sich leicht in den Arbeitsalltag integrieren lassen.

Anbieter	Zielgruppe	KI-Coaching	Menschlicher Coach	Schwerpunkt
CoachHub [15]	Unternehmen	Ja	Ja	Leadership & Business Coaching
BetterUp [16]	Unternehmen	Ja	Ja	Leadership Development
Rocky.ai [17]	Unternehmen	Ja	Optional	Selbstreflexion & Micro Coaching
Sherlock AI [18]	Unternehmen	Ja	Nein	Coaching-native KI
Wysa [19]	Privatpersonen	Ja	Optional	Mental Health
Woebot Health [20]	Unternehmen/ Gesundheit	Ja	Nein	CBT & mentale Gesundheit
Delenta AI	Coaches	Ja	Ja	Unterstützung professioneller Coaches

Tabelle 1: Überblick über ausgewählte Anbieter

Anmerkung. Eigene Darstellung auf Grundlage der öffentlich verfügbaren Informationen der jeweiligen Anbieter-Webseiten, abgerufen im August 2026.

[15] CoachHub. (2026). CoachHub – Die digitale Coaching-Plattform. <https://www.coachhub.com/de>

[16] BetterUp. (2026). BetterUp AI Coach. <https://support.betterup.com/hc/en-us/articles/36688702739611-BetterUp-AI-Coach>

[17] Rocky.ai. (2026). AI coaching platform tailored to your company. <https://www.rocky.ai/>

[18] Sherlock Performance AI. (2026). Sherlock AI. <https://www.sherlockperformance.com/>

[19] Wysa. (2026). Wysa – Everyday mental health. <https://www.wysa.com/>

[20] Woebot Health. (2026). Woebot Health. <https://woebothealth.com/>

[21] Delenta. (2026). AI in coaching. <https://www.delenta.com/ai-in-coaching>

Eine Besonderheit stellt *Sherlock AI* dar. Nach Angaben der Entwickler wurde die Plattform von Beginn an als Coaching-System konzipiert und nicht durch die Anpassung eines allgemeinen Sprachmodells entwickelt. Die Coachingdialoge orientieren sich an strukturierten Coaching-Journeys und wurden gemeinsam mit erfahrenen Coaches entwickelt und iterativ getestet [22].

Im Bereich der mentalen Gesundheit haben sich Anbieter wie *Woebot Health* und *Wysa* etabliert. Beide Systeme basieren auf evidenzbasierten Methoden der kognitiven Verhaltenstherapie (CBT) und dienen primär der psychologischen Unterstützung. Obwohl diese Anwendungen kein Coaching im engeren Sinne darstellen, liefern sie wertvolle Erkenntnisse hinsichtlich Sicherheitsmechanismen, Dialoggestaltung und Nutzerakzeptanz.

Vergleich mit den wissenschaftlichen Anforderungen

Ein Vergleich der Marktanalyse mit den in Kapitel 1.2 dargestellten Forschungsergebnissen zeigt, dass zahlreiche Anbieter bereits einzelne wissenschaftliche Empfehlungen umsetzen. Hierzu zählen insbesondere strukturierte Dialoge, personalisierte Inhalte sowie hybride Modelle mit menschlicher Unterstützung.

Gleichzeitig bestehen weiterhin deutliche Unterschiede hinsichtlich Transparenz, methodischer Fundierung und technischer Architektur. Nur wenige Anbieter veröffentlichen Informationen über die zugrunde liegenden Coachingmethoden, Sicherheitsmechanismen oder den Einsatz von Guardrails, Retrieval-Augmented Generation (RAG) oder Human Oversight. Ebenso bleibt häufig unklar, wie Coaching von therapeutischen Interventionen abgegrenzt wird und welche Qualitätsstandards den Dialogen zugrunde liegen.

Insbesondere bei generativen Sprachmodellen besteht die Herausforderung, dass überzeugend formulierte Antworten nicht zwangsläufig methodisch korrekt sind. Die

[22] Brahmasmi, P. & Bali, D. (2025). Pioneering & designing the world's first coaching-native AI: Principles, challenges, and enterprise applications. Columbia Coaching Conference 2025.

<https://www.columbiacoachingconference.org/post/pioneering-designing-the-world-s-first-coaching-native-ai-principles-challenges-and-enterprise>

wissenschaftlich geforderte strukturierte Gesprächsführung wird bislang nur von wenigen spezialisierten Lösungen konsequent umgesetzt.

Die Marktanalyse zeigt, dass KI-gestützte Coaching-Lösungen zunehmend an Bedeutung gewinnen und bereits in unterschiedlichen Anwendungsfeldern eingesetzt werden. Der Markt wird derzeit jedoch von hybriden Modellen dominiert, bei denen KI menschliche Coaches ergänzt, anstatt sie vollständig zu ersetzen.

Gleichzeitig bestehen weiterhin Defizite hinsichtlich Transparenz, methodischer Nachvollziehbarkeit und der konsequenten Umsetzung wissenschaftlicher Qualitätsanforderungen. Insbesondere die Integration strukturierter Coachingmethoden, domänenspezifischer Sicherheitsmechanismen sowie nachvollziehbarer ethischer Standards ist bislang nur begrenzt erkennbar.

Aus der Kombination von Forschungsstand und Marktanalyse ergibt sich daher die Notwendigkeit, Anforderungen an einen KI-basierten Coach systematisch abzuleiten. Diese Anforderungen werden im folgenden Kapitel entwickelt und bilden die Grundlage für die Konzeption der in dieser Arbeit vorgestellten Plattform.

2. Anforderungskatalog für eine KI-gestützte Coachingplattform

Nach der Analyse des Forschungsstands sowie der Markt- und Regulierungslandschaft stellt sich die Frage, welche Anforderungen eine KI-gestützte Coachingplattform erfüllen muss, um fachlich fundiert, technisch leistungsfähig und verantwortungsvoll eingesetzt werden zu können. Die bisherigen Kapitel haben gezeigt, dass sich Nutzende zunehmend an KI-Systeme wenden, gleichzeitig jedoch erhebliche Risiken hinsichtlich Datenschutz, ethischer Verantwortung und fachlicher Qualität bestehen.

Im Folgenden werden daher die wesentlichen Anforderungen an einen KI-Coach systematisch zusammengefasst. Der Anforderungskatalog dient als konzeptionelle Grundlage für die im weiteren Verlauf dieser Arbeit beschriebene technische Umsetzung. Die Anforderungen leiten sich aus der wissenschaftlichen Literatur,

geltenden rechtlichen Rahmenbedingungen, etablierten Coachingstandards sowie den identifizierten Nutzerbedürfnissen ab und umfassen folgende Bereiche:

- Nutzeranforderungen (User Requirements)
- Fachliche Coaching-Anforderungen
- Ethische Anforderungen
- Rechtliche Anforderungen
- Funktionale Anforderungen
- Nichtfunktionale Anforderungen
- KI-spezifische Nichtfunktionale Anforderungen

2.1 Nutzeranforderungen (User Requirements)

Die Akzeptanz und Wirksamkeit einer KI-gestützten Coachingplattform hängen maßgeblich davon ab, inwieweit sie die Erwartungen und Bedürfnisse ihrer Nutzerinnen und Nutzer erfüllt. Diese Anforderungen gehen über die reine technische Funktionalität hinaus und umfassen insbesondere die Qualität der Gesprächsführung, die Benutzerfreundlichkeit sowie den vertrauensvollen Umgang mit persönlichen Informationen. Für die Nutzenden ergeben sich zwei Bereiche der Nutzeranforderungen, einerseits an die Coachingqualität, das eigentliche inhaltliche Erlebnis zum anderen an die Funktionalität der digitalen Plattform.

Erwartungen an die Coachingqualität

- vertrauensvolle Gesprächsatmosphäre
- wertschätzende und respektvolle Kommunikation
- aktives Zuhören
- gezielte Reflexionsfragen statt vorschneller Ratschläge
- Unterstützung bei Zielklärung
- Strukturierung komplexer Gedanken
- Hilfe bei Entscheidungsfindung
- Förderung von Selbstreflexion
- individuelle Gesprächsführung
- Berücksichtigung des bisherigen Gesprächsverlaufs
- Konsistenz über mehrere Sitzungen hinweg

Erwartungen an die Funktionalität

- jederzeit verfügbar (24/7)
- niedrige Zugangshürde
- intuitive Bedienung
- schnelle Antwortzeiten
- Nutzung über verschiedene Endgeräte
- mehrsprachige Kommunikation
- transparente Funktionsweise
- Kontrolle über eigene Daten

2.2 Fachliche Coaching-Anforderungen

Neben den Erwartungen der Nutzerinnen und Nutzer muss eine KI-gestützte Coachingplattform den fachlichen Grundsätzen professionellen Coachings entsprechen. Ziel ist es, Coachingprozesse zu unterstützen, ohne die Rolle einer therapeutischen oder beratenden Fachkraft zu übernehmen. Die folgenden Anforderungen orientieren sich an etablierten Coachingstandards und wissenschaftlichen Erkenntnissen zur wirksamen Gesprächsführung.

- Orientierung an anerkannten Coachingstandards (z. B. ICF [9], EMCC [23], DBVC [7], DGSC [8])
- systemische Fragetechniken
- lösungsorientierte Gesprächsführung
- ressourcenorientierter Ansatz
- keine Diagnosestellung
- keine Therapie
- keine medizinischen Empfehlungen
- Förderung der Eigenverantwortung
- Vermeidung von Suggestivfragen
- Vermeidung von Abhängigkeiten
- klare Rollenkommunikation (KI ist Coach, kein Therapeut)

[23] European Mentoring and Coaching Council (2015). EMCC COMPETENCE FRAMEWORK V2
<https://www.emccglobal.org/wp-content/uploads/2018/10/EMCC-competences-framework-v2-EN.pdf>

2.3 Ethische Anforderungen

Der Einsatz generativer KI im Coaching wirft eine Vielzahl ethischer Fragestellungen auf. Insbesondere die Gefahr manipulativer Gesprächsführung, unangemessener emotionaler Bindung oder fehlerhafter Empfehlungen erfordert klare Leitlinien für die Entwicklung und den Betrieb eines KI-Coaches. Die folgenden Anforderungen sollen einen verantwortungsvollen und vertrauenswürdigen Einsatz der Technologie gewährleisten.

- Transparenz über KI-Nutzung
- Offenlegung der Grenzen des Systems
- Wahrung der Autonomie der Nutzenden
- Vermeidung manipulativer Gesprächsführung
- keine emotionale Bindungsstrategie
- keine übermäßige Bestätigung (Sycophancy)
- Förderung kritischer Selbstreflexion
- diskriminierungsfreie Kommunikation
- Fairness
- Nachvollziehbarkeit wichtiger Entscheidungen
- Krisenerkennung
- Eskalation bei psychischen Krisen
- Hinweis auf professionelle Hilfe
- verantwortungsvoller Umgang mit Halluzinationen

2.4 Rechtliche Anforderungen

Neben fachlichen und ethischen Aspekten müssen beim Betrieb einer KI-gestützten Coachingplattform auch die geltenden rechtlichen Rahmenbedingungen berücksichtigt werden. Insbesondere Anforderungen aus dem europäischen AI Act [6], der Datenschutz-Grundverordnung (DSGVO) sowie dem Verbraucherrecht bilden die Grundlage für einen rechtskonformen Einsatz der Plattform.

Datenschutz

- DSGVO-Konformität
- Einwilligungsmanagement
- Datenminimierung
- Zweckbindung
- Löschkonzepte
- Export persönlicher Daten
- Verschlüsselung
- Zugriffsschutz

AI Act

- Transparenzpflichten
- Kennzeichnung der KI
- Information über KI-generierte Inhalte
- Risikomanagement
- Dokumentation

Compliance

- Impressum
- Datenschutzerklärung
- Nutzungsbedingungen
- Haftungshinweise

2.5 Funktionale Anforderungen

Die funktionalen Anforderungen beschreiben die konkreten Funktionen und Eigenschaften, die eine KI-gestützte Coachingplattform bereitstellen muss, um den Coachingprozess wirksam zu unterstützen. Sie bilden die Grundlage für die technische Umsetzung und definieren den erforderlichen Leistungsumfang der Anwendung.

Benutzerverwaltung

- Benutzerkonto
- Login
- Rollenmodell
- Passwortverwaltung
- Single Sign-on (optional)

Coaching

- neue Coaching-Session starten
- Sitzungen fortsetzen
- Gesprächshistorie
- automatisches Mitschreiben
- Zusammenfassungen
- Aktionspläne
- Zieldefinition
- Fortschrittskontrolle
- Erinnerungen
- Hausaufgaben
- Follow-up

Wissensmanagement

- persönlicher Coachingverlauf
- Notizen
- Dokumentenablage
- Upload eigener Dokumente
- Verknüpfung mehrerer Sessions

Analyse

- Zielverfolgung
- Entwicklung über mehrere Sitzungen
- wiederkehrende Themen erkennen
- Stärkenanalyse

- Werteanalyse
- Visualisierung von Fortschritten

2.6 Nichtfunktionale Anforderungen

Neben den funktionalen Anforderungen sind für eine KI-gestützte Coachingplattform auch technische Qualitätsmerkmale von entscheidender Bedeutung. Sie gewährleisten einen sicheren, zuverlässigen und leistungsfähigen Betrieb der Plattform und berücksichtigen zugleich die besonderen Eigenschaften generativer KI-Systeme. Dazu zählen Anforderungen an Sicherheit, Performance und Skalierbarkeit ebenso wie Mechanismen zur Qualitätssicherung der KI, zur Steuerung des Sprachmodells und zur kontinuierlichen Weiterentwicklung des Systems.

Systemqualität

- Hohe Systemverfügbarkeit
- Kurze Antwortzeiten
- Hohe Skalierbarkeit bei steigenden Nutzerzahlen
- Robuste und fehlertolerante Systemarchitektur
- Plattformunabhängige Nutzung (Desktop, Tablet, Smartphone)
- Barrierearme und intuitive Benutzeroberfläche

Informationssicherheit

- Verschlüsselte Datenübertragung (TLS)
- Verschlüsselte Datenspeicherung
- Sichere Authentifizierung
- Rollen- und Berechtigungskonzepte
- Backup- und Wiederherstellungsmechanismen
- Protokollierung sicherheitsrelevanter Ereignisse

Wissensmanagement

- Integration externer Wissensquellen (Retrieval-Augmented Generation, RAG)
- Nutzung einer kuratierten Wissensbasis
- Quellenangaben für fachliche Aussagen (soweit technisch möglich)

- Trennung zwischen allgemeinem Modellwissen und projektspezifischem Wissen

2.7 KI spezifische Nichtfunktionale Anforderungen

KI-Architektur

- Einsatz aktueller Large Language Models
- Konfigurierbare System-Prompts
- Steuerbare Gesprächsstrategie
- Mehrstufige Prompt-Architektur (z. B. System-, Rollen- und Sitzungs-Prompts)
- Nutzung von Memory über mehrere Coaching-Sitzungen
- Kontextverwaltung zur Berücksichtigung früherer Gespräche

Qualitätssicherung der KI

- Minimierung von Halluzinationen
- Konsistenz der Gesprächsführung
- Einhaltung definierter Coaching-Prinzipien
- Erkennung kritischer Gesprächssituationen
- Mechanismen zur Weiterleitung an menschliche Unterstützung bei Krisenfällen
- Regelmäßige Evaluation der Antwortqualität

Monitoring und Weiterentwicklung

- Versionierung von Prompts
- Versionierung der Wissensbasis
- Nutzerfeedback zur Antwortqualität
- Monitoring der Systemleistung
- Monitoring der KI-Antwortqualität
- Kontinuierliche Optimierung anhand wissenschaftlicher Erkenntnisse und Nutzerfeedback
- Nachvollziehbarkeit von Änderungen an der Plattform

3. Technische Umsetzung der Plattform KICO

3.1 Architekturprinzipien: Warum Methode Architektur braucht

Ausgangslage: Was kommerzielle Sprachmodelle nicht leisten

Bevor die Plattform selbst beschrieben wird, lohnt ein präziser Blick auf den Ausgangszustand. Ein Sprachmodell wie Claude, GPT-4 oder Gemini ist zunächst als allgemeines Sprachmodell konzipiert und verfügt nicht automatisch über eine für Coaching optimierte Gesprächsstruktur. Untersuchungen zum Gesprächsverhalten von Large Language Models zeigen, dass solche Systeme im Vergleich zu menschlichen Therapeuten häufiger direkte Ratschläge, Psychoedukation und Bestätigung geben, während sie weniger klärende und empathische Fragen stellen. Dadurch besteht die Gefahr, dass Nutzer zwar unmittelbar Unterstützung und Validierung erfahren, jedoch weniger zur eigenständigen Reflexion und vertieften Exploration ihrer Situation angeregt werden [24]. Diese Unterschiede verdeutlichen, dass ein für Coaching eingesetztes Sprachmodell gezielt durch Systemprompting, Gesprächsarchitektur und Sicherheitsmechanismen auf eine coachinggerechte Gesprächsführung ausgerichtet werden muss.

Vier Entscheidungen, die alles andere prägen

Der Aufbau der Plattform folgt vier Grundprinzipien, die methodische Überzeugungen in technische Entscheidungen übersetzen.

[24a] Scholich, T., Barr, M., Wiltsey Stirman, S., & Raj, S. (2025). A comparison of responses from human therapists and large language model-based chatbots to assess therapeutic communication: Mixed methods study. JMIR Mental Health, 12, e69709. <https://doi.org/10.2196/69709>

[24b] Wei, M. (2025). New studies reveal mental health blindspots of AI chatbots. Psychology Today. <https://www.psychologytoday.com/us/blog/urban-survival/202510/new-studies-reveal-mental-health-blindspots-of-ai-chatbots>

Das erste lautet: Methode vor Modell. Die Coaching-Methodik des INA CCW-Curriculums ist als verbindlicher Rahmen in die Konfiguration des Sprachmodells eingebettet. Das Modell improvisiert nicht. Es arbeitet innerhalb eines definierten Methodenkorpus: U-Modell, Skalierungsfragen, Auftragsklärung, systemische Fragetechniken, Inneres Team, Fünf Säulen der Identität, und weitere Werkzeuge, die nach Gesprächsphase geordnet sind. Die Grundlage für diese Konfiguration war das tatsächliche Ausbildungsmaterial des INA CCW-Curriculums, das im Verlauf der Entwicklung erstmals vollständig gesichtet und ausgewertet wurde.

Das zweite Prinzip: Sicherheit vor dem Modell. Kritische Erkennungsfunktionen laufen nicht im Sprachmodell, sondern davor. Bevor eine Nutzereingabe das Modell erreicht, prüft ein regelbasierter Filter auf Krisensignale, ohne Interpretationsspielraum und ohne Abhängigkeit davon, wie das Modell den Kontext gerade einschätzt. Bei der höchsten Risikostufe (akuter Krise) wird das Modell gar nicht erst aufgerufen. Bei niedrigeren Risikostufen wird das Signal erkannt und protokolliert, der Modellaufruf läuft aber weiter, weil das Modell bei diesen Signalen seine kontextsensitive Nuancierungsfähigkeit einbringen soll. Diese Entscheidung folgt direkt aus einem Befund der Forschungsliteratur: Sprachmodelle, die durch Standard-Sicherheitstraining auf harmlose Ausgaben optimiert wurden, reagieren auf mittlere Risikosignale inkonsistent, weil ihr Sicherheitsverhalten nicht zwischen schädlichen und methodisch notwendigen Inhalten unterscheiden kann [13].

Das dritte Prinzip: Kontext statt Sitzung. Die Plattform denkt in Prozessen, nicht in Einzelgesprächen. Erkenntnisse und Themen aus früheren Sessions sollen beim nächsten Gespräch präsent sein, ohne dass der Coachee sie jeweils neu einführen muss. Zum Stand August 2026 ist dieser Teil der Architektur konzipiert, aber noch nicht vollständig umgesetzt. Jede Session startet derzeit für das Modell ohne Langzeitgedächtnis. Das ist die größte verbleibende Lücke zwischen dem formulierten Anspruch und dem tatsächlichen Betrieb.

Das vierte Prinzip: Gateway statt Endpunkt. Die Plattform erhebt keinen Anspruch, menschliches Coaching zu ersetzen. Ein systematischer Review aus dem Jahr 2025 zeigt, dass Verbesserungen durch KI-Coaching allein nach Abschluss der Intervention schlechter anhalten als in Hybrid-Prozessen [11]. Die Plattform ist als

strukturierter Einstieg konzipiert, der aktiv auf den Übergang zu menschlicher Begleitung vorbereitet.

Was eine Konfiguration garantieren kann und was nicht

Ein Sprachmodell lässt sich über eine vorgelagerte Instruktion (System Prompt) konfigurieren. Diese Instruktion definiert Rolle, Verhalten und Grenzen des Modells und wird vom Modell mit hoher, aber nicht absoluter Verlässlichkeit befolgt. Der entscheidende Punkt: Eine Instruktion ist eine Bitte, keine technische Sperre. In Momenten, in denen Gesprächskontext und Verhaltensregel in Konflikt geraten, muss das Modell abwägen, und diese Abwägung kann falsch ausfallen [13].

Für eine Alltagsanwendung ist das tolerierbar. Für eine Plattform, die Menschen in psychologisch relevanten Prozessen begleitet, hat der Unterschied zwischen "mit hoher Wahrscheinlichkeit" und "verlässlich" methodisches Gewicht. Die Antwort auf dieses Problem ist nicht, ein besseres Modell zu wählen. Sie ist, bestimmte Funktionen aus dem Modell herauszunehmen und in eigenständige, modellunabhängige Schichten zu überführen.

Zwei solcher Schichten sind in *KICO* umgesetzt. Die erste ist der regelbasierte Krisenfilter: Er prüft jede Eingabe auf Krisenbegriffe, bevor das Modell sie überhaupt sieht. Bei einem akuten Krisensignal wird das Modell nicht aufgerufen. Das adressiert einen in der Forschung dokumentierten Effekt: Sicherheitsmechanismen in Sprachmodellen werden in langen Gesprächen weniger zuverlässig [13]. Der Filter umgeht diesen Effekt strukturell, zumindest für die schwerwiegendsten Signale.

Die zweite Schicht sind persistente Coaching-Anker. Wichtige Erkenntnisse aus dem Gespräch werden nicht nur im Gesprächsverlauf festgehalten, sondern als dauerhaft sichtbare Elemente in der Session verankert. Dabei gibt es zwei Varianten: Das Modell kann einen Anker setzen, wenn es eine zentrale Erkenntnis identifiziert. Oder der Coachee formuliert selbst, was er festhalten möchte. Diese zweite Variante ist methodisch die stärkere: Der Coachee bleibt Autor seiner eigenen Coaching-Erkenntnisse, das Modell paraphrasiert sie nicht.

Beide Schichten illustrieren ein Prinzip, das für die gesamte Architektur gilt: Das Versprechen "Methode vor Modell" lässt sich nicht vollständig durch eine gute

Konfiguration einlösen. Es erfordert Schichten, die unabhängig vom Verhalten des Modells operieren.

3.2 Umsetzung: Gespräch, Regeln und Daten

Wie ein Gespräch auf der Plattform verläuft

Das zentrale Prozessmodell des INA CCW-Curriculums ist das U-Modell nach Otto Scharmer. Es beschreibt eine Gesprächsbewegung, die von der Situationsbetrachtung über das Vertiefen und einen Wendepunkt bis hin zur konkreten nächsten Handlung führt. *KICO* übersetzt dieses Modell in fünf Gesprächsphasen.

Die erste Phase heißt Ankommen und Auftragsklärung. Sie vereint zwei Schritte, die im systemischen Coaching bewusst gesetzt werden: das Herstellen von Kontakt und Orientierung, und das Klären des Rahmens und der Erwartungen. In dieser Phase fragt die Plattform nach dem Kontext, in dem der Coachee sich gerade befindet, und schärft gemeinsam mit ihm, was das Anliegen der Session sein soll. Das Modell erhebt hier auch, wer in der Situation beteiligt ist und was der Coachee am Ende der Session anders sehen möchte. Keine Bewertung, kein Ratschlag, kein Vorwegnehmen.

Die zweite Phase ist die Vertiefung. Das Anliegen wird in seiner systemischen Einbettung erkundet. Was genau soll sich verändern? Welche Muster sind sichtbar? Welche Ressourcen sind vorhanden?

Die dritte Phase ist der Wendepunkt. Das ist die Kernphase des Gesprächs. Je nach Anliegen arbeitet die Plattform mit systemischen Fragen, Perspektivwechseln, der Erkundung innerer Anteile oder anderen Werkzeugen aus dem Methodenkorpus. Diese Phase ist bewusst nicht zeitlich begrenzt. Sie dauert, bis der Coachee signalisiert, dass etwas in Bewegung gekommen ist.

Die vierte Phase ist der Lösungsraum. Erkenntnisse werden artikuliert, und erste mögliche Richtungen werden sichtbar gemacht. Die Plattform fragt nicht nach einem

vollständigen Plan, sondern danach, was neu sichtbar geworden ist und wohin das weisen könnte.

Die fünfte Phase ist der Transfer. Der Coachee formuliert einen konkreten nächsten Schritt. Zum Stand August 2026 ist diese Phase im Gespräch vorhanden, aber noch nicht mit einem methodischen Abschlussritual versehen. Gespräche enden derzeit durch Wegnavigieren, nicht durch einen bewussten Gesprächsabschluss.

Die Regeln, nach denen die Plattform arbeitet

Die Konfiguration des Sprachmodells übersetzt die methodischen Anforderungen aus Kapitel 2 in verbindliche Verhaltensregeln. Die Plattform stellt Fragen und gibt keine Ratschläge. Pro Antwort genau eine Frage. Jede Antwort endet mit einer offenen Frage oder einer Einladung zur Reflexion. Diese Einschränkung ist empirisch begründet: Forschung zeigt, dass die Wirksamkeit von KI-Coaching messbar sinkt, wenn das Modell mehrere Fragen gleichzeitig stellt [10].

Wenn der Coachee Bestätigung sucht, bestätigt die Plattform nicht. Wenn jemand fragt "Habe ich das richtig gemacht?", gibt die Plattform die Frage zurück: "Was sagt dein Gefühl dazu?" Damit soll die eigenständige Reflexion des Coachees gefördert werden. Untersuchungen zeigen, dass Large Language Models im Vergleich zu menschlichen Therapeuten häufiger Affirmation, Beruhigung, Psychoedukation und direkte Vorschläge verwenden. Dies kann dazu führen, dass Nutzer zwar unmittelbar Bestätigung und Unterstützung erhalten, aber weniger zur vertieften Exploration ihrer eigenen Situation angeregt werden [24]. Darüber hinaus wurde bei aktuellen Sprachmodellen ein sogenanntes sycophantisches Verhalten beobachtet, bei dem das Modell die Position oder Einschätzung des Nutzers übermäßig bestätigt. OpenAI hat ein solches Verhalten bei einem GPT-4o-Update 2025 selbst dokumentiert und als unerwünschtes Verhalten bezeichnet [25,26]. Die Konfiguration von *KICO* widerspricht der sycophantischen Tendenz aktiv.

Die Plattform benennt sich nicht als Coach, Therapeutin oder Mensch.

Formulierungen, die menschliche Präsenz simulieren, sind nicht erlaubt. Auf der Anmeldeseite der Plattform steht sichtbar "Forschungsprototyp". Diese Transparenz ist keine optionale Ergänzung, sondern eine Anforderung des ICF Code of Ethics 2025 [9].

Wenn ein akutes Krisensignal erkannt wird, unterbricht die Plattform den Coaching-Prozess und nennt konkrete Anlaufstellen. Die Telefonseelsorge (0800 111 0 111, kostenlos, 24/7) ist in der deutschsprachigen Version fest hinterlegt. Die Art und Weise, wie diese Reaktion formuliert ist, wurde aus einem Nutzungstest überarbeitet. Die ursprüngliche Version war sachlich korrekt, aber kalt formuliert. Sie wirkte wie eine automatisierte Zurückweisung genau in dem Moment, in dem sich jemand verletzlich zeigte. Die überarbeitete Version beginnt mit Anerkennung, bevor sie auf Ressourcen hinweist. Weder der Ton noch das Timing dieser Reaktion wurden klinisch geprüft. Das ist eine offen benannte Lücke.

Eine weitere Regel betrifft die Coachingfrage selbst. Wenn der Coachee eine Frage formuliert, die rückwärtsgewandt ist oder externe Ursachen in den Mittelpunkt stellt, stellt die Plattform genau eine Gegenfrage, die eine andere Formulierung ermöglicht. Sie schlägt keine eigene Alternativfrage vor. Das wäre eine Überschreitung: Ein Coach, der die Frage seines Coachees selbst umformuliert, übernimmt Verantwortung, die dem Coachee gehört.

Wie die Plattform Daten verarbeitet

Jedes Gespräch auf der Plattform durchläuft vier Verarbeitungsebenen, die aufeinander aufbauen.

Während des Gesprächs läuft jede Eingabe durch den regelbasierten Krisenfilter, bevor das Sprachmodell sie verarbeitet. Parallel dazu wird jede Nachricht, sowohl vom Coachee als auch von der Plattform, unmittelbar in der Datenbank gespeichert. Das Rohtranskript ist vollständig und unverändert. Es ist das einzige vollständige Archiv des Gesprächs.

[25] OpenAI. (2025a). Sycophancy in GPT-4o: What happened and what we're doing about it.
<https://openai.com/index/sycophancy-in-gpt-4o/>

[26] OpenAI. (2025b). Expanding on what we missed with sycophancy.
<https://openai.com/index/expanding-on-sycophancy/>

Am Ende einer Session soll aus diesem Rohtranskript eine strukturierte Gesprächsnotiz generiert werden: Was der Coachee mitgebracht hat, was im Gespräch sichtbar wurde, was sich verändert hat, was offen geblieben ist. Diese Notiz soll keine Zusammenfassung sein, sondern ein Spiegel: Sie bewahrt Widersprüche und offene Fragen, anstatt sie aufzulösen. Zum Stand August 2026 ist diese Funktion noch nicht gebaut.

Zu Beginn der nächsten Session sollen diese Notizen und ein fortlaufend aktualisiertes Coaching-Profil in das Gespräch eingebracht werden, ohne dass der Coachee sie jeweils neu einführen muss. Auch diese Funktion ist noch nicht gebaut. Bis sie existiert, beginnt jede Session für das Modell ohne Langzeitgedächtnis.

Die Daten werden ausschließlich auf europäischen Servern gespeichert. Gespräche sind durch technische Zugriffskontrollen auf Datenbankebene so geschützt, dass kein Nutzer auf Gespräche eines anderen zugreifen kann, auch nicht bei Fehlkonfiguration der Plattform selbst. Audio wird nicht gespeichert; im Voice-Modus wird das Transkript gespeichert, nicht die Aufnahme.

3.3 Voice-Architektur und offene Fragen

Warum Sprachbasierte Coaching-Gespräche eine eigene technische Lösung brauchen

Textbasierte Coaching-Gespräche sind technisch vergleichsweise einfach umzusetzen. Gespräche per Sprache stellen eine andere Kategorie von Anforderungen dar. Im systemischen Coaching ist die Art, wie jemand spricht, mindestens so aussagekräftig, wie das, was gesagt wird. Sprechpausen, Zögern, veränderte Sprechgeschwindigkeit sind diagnostisch relevante Signale. Eine Sprachlösung, die diese Signale durch Systemunterbrechungen zerstört, produziert kein Coaching.

Die erste Voice-Implementierung der Plattform nutzte ein Sprachmodell von OpenAI, das Audio nativ verarbeitet. Im Betrieb zeigte sich ein grundlegendes Problem: Das System unterbrach den Coachee bei Denkpausen. Es erkannte Stille als Gesprächsende und antwortete, bevor der Coachee fertig gesprochen hatte. Alle

technischen Konfigurationsversuche, dieses Verhalten zu ändern, scheiterten. Die einzige funktionierende Lösung war ein manueller Sprechaste-Modus, bei dem der Coachee einen Knopf halten muss, um zu sprechen. Technisch funktional, methodisch ein Rückschritt.

Eine erneute Analyse ergab zusätzliche strukturelle Probleme dieser Architektur: ein harter Zeitdeckel von 60 Minuten pro Gespräch, keine Möglichkeit, ein unterbrochenes Gespräch fortzusetzen, und kein verlässliches Texttranskript als Grundlage für die geplante Gesprächsnotiz. Diese drei Probleme bestehen unabhängig davon, ob das Unterbrechungsproblem gelöst wird.

Die Entscheidung fiel deshalb auf eine andere Architektur: Sprache wird in Text umgewandelt, der Text wird von *Claude* verarbeitet, die Antwort wird in Sprache umgewandelt. Diese Kette ist langsamer als ein natives Sprachmodell, aber sie liefert ein vollständiges Transkript, sie hat keinen Zeitdeckel, und sie erlaubt ein konfigurierbares Erkennen, wann jemand aufgehört hat zu sprechen.

Dieser letzte Punkt ist der methodisch entscheidende. Das Schweige-Problem, das in der ersten Architektur unlösbar war, lässt sich in der neuen Architektur direkt konfigurieren. Der Parameter, der bestimmt, wie lange das System auf Stille wartet, bevor es von einem Gesprächsende ausgeht, ist auf zwei Sekunden gesetzt. Der Standardwert solcher Systeme liegt bei 0,2 Sekunden. Ein vollständiger Gesprächstest am 29. Juli 2026 bestätigte, dass zwei Sekunden sich in der Praxis gut anfühlen und keine vorzeitigen Unterbrechungen erzeugen. Dieser Wert ist ein kalibrierter Startwert, der nach weiteren Nutzungstests angepasst wird.

Für Voice-Gespräche wird *Deepgram* als Spracherkennungsdienst genutzt, über einen europäischen Server. Die Sprachausgabe erfolgt über deutsche Stimmen, die für Natürlichkeit im deutschsprachigen Kontext ausgewählt wurden. Die gesamte Voice-Pipeline läuft über Server in Frankfurt. Offen geblieben ist die Frage, ob auch der *Claude*-Sprachmodelldienst selbst auf europäischen Servern verarbeitet wird. Diese Frage ist für den Forschungsrahmen dieser Arbeit dokumentiert und zurückgestellt, muss aber vor einer Weiterentwicklung über diesen Rahmen hinaus geklärt werden.

Was bleibt bei längerer Stille? Wenn ein Coachee mehr als zwei Sekunden schweigt, hat das System keine eingebaute Reaktion. Im systemischen Coaching ist Stille ein Werkzeug: Sie gibt Raum für Gedanken, die noch nicht formuliert sind. Jede vorzeitige Reaktion verkleinert diesen Raum. Ob ein kurzes Atemgeräusch, ein neutrales akustisches Signal oder bewusstes Offenlassen der Stille die methodisch richtige Reaktion wäre, ist eine Frage, die in dieser Arbeit nicht abschließend beantwortet wird und einer empirischen Untersuchung bedarf.

Was umgesetzt ist und was nicht

Die Architekturentscheidungen, die diese Plattform von einem konfigurierten Allzweck-Chatbot unterscheiden, lassen sich in drei Gruppen einteilen.

Vollständig umgesetzt sind der regelbasierte Krisenfilter vor dem Sprachmodell, die fünfphasige Gesprächsstruktur nach dem U-Modell, die Coaching-Konfiguration mit dem INA CCW-Methodenkörper, die persistenten Gesprächsanker, die Voice-Architektur mit konfigurierbarer Schweigeerkennung, und die europäische Datenspeicherung für alle erfassten Daten.

Teilweise umgesetzt sind die Abgrenzung von Coaching und Therapie (als Konfigurationsregel vorhanden, aber ohne nachgelagerte automatische Überprüfung jeder Antwort), der INA CCW-Methodenkörper (die Phasenstruktur und rund 25 Werkzeuge sind integriert, eine feinere Auswahllogik innerhalb einzelner Phasen fehlt noch), und die datenschutzrechtliche Vollständigkeit im Voice-Modus (Deepgram und Pipecat laufen auf europäischen Servern, die Datenresidenz von Anthropic im Voice-Betrieb ist noch nicht geprüft).

Noch nicht umgesetzt sind das Langzeitgedächtnis über Sessions hinweg, der Abschlussritus am Ende einer Session, ein strukturiertes Einwilligungsverfahren bei Gesprächsbeginn, und eine Möglichkeit für Coachees, ihre eigenen Gesprächsdaten einzusehen oder zu löschen.

Diese Lücken werden nicht als Vollständigkeitsmangel berichtet, sondern als Befund: Sie zeigen, was eine erste Version einer methodisch ernst gemeinten KI-Coaching-Plattform kosten würde, wenn sie alle Anforderungen aus Kapitel 2 vollständig einlösen wollte. Einige davon sind nicht integriert worden, da sie

aufwendig sind. Andere, wie das Langzeitgedächtnis, sind nicht erstellt worden, weil sie konzeptionell anspruchsvoll sind und eine sorgfältige Antwort auf Datenschutzfragen erfordern, die im Forschungsrahmen dieser Arbeit offen bleiben können.

Positionierung gegenüber bestehenden Systemen

Das einzige dokumentierte Beispiel einer KI-Coaching-Plattform, die von Grund auf als Coaching-System entwickelt wurde und nicht durch Anpassung eines Allzweck-Sprachmodells, ist *Sherlock AI*, vorgestellt auf der Columbia Coaching Conference 2025. Die Plattform entstand iterativ mit erfahrenen Coaches, ohne generische vortrainierte Datensätze, und investierte sechs bis acht Monate Entwicklungsaufwand pro Coaching-Modul [18].

KICO folgt denselben Designprinzipien, unterscheidet sich aber in einer pragmatischen Entscheidung: Die Plattform verzichtet auf eigenes Modell-Training und setzt stattdessen auf eine strukturierte Konfiguration und vorgelagerte Architekturschichten, um ein bestehendes Sprachmodell in einen Coaching-Kontext einzubetten. Das ist eine Entscheidung für eine erste Version. Sie ist gut begründet: Forschung zeigt, dass die grundlegenden Grenzen von KI im Coaching kein Modellierungsproblem sind [27]. Methodische Integrität, Sicherheitsarchitektur und ein klarer Übergabepunkt zu menschlichen Coaches sind die entscheidenden Stellschrauben. Alle drei lassen sich über Architektur adressieren.

3.4 Reflektion des Status Quo und Limitierung der technischen Lösung hin zu einer vollumfänglichen digitalen Lösung

Die vorangegangene Übersicht beschreibt den Stand der Plattform als Momentaufnahme. Für die Frage, was zwischen diesem Forschungsprototyp und

[27] Passmore, J. & Tee, D. (2024). AI coaching: Democratising coaching service or offering an illusion? International Journal of Evidence Based Coaching and Mentoring.
<https://doi.org/10.1080/17521882.2024.2368598>

einer vollumfänglichen digitalen Lösung liegt, ist jedoch weniger relevant, was im Einzelnen fehlt, als warum es fehlt. Die offenen Punkte lassen sich vier unterschiedlichen Kategorien zuordnen, die sich in ihrem Aufwand, ihrer Reife und ihrer Lösbarkeit deutlich unterscheiden.

Nachrüstbare Lücken

Ein Teil der offenen Punkte, nämlich der Abschlussritus am Ende einer Session, ein struktureller Einwilligungsbildschirm, eine Ansicht zum Einsehen und Löschen eigener Daten, eine feinere Tool-Auswahllogik innerhalb der bereits bestehenden Phasenstruktur, ist konzeptionell klar umrissen und ließe sich ohne grundlegende Architekturänderung ergänzen. Ihr Fehlen ist eine Frage der investierten Entwicklungszeit, nicht der technischen Machbarkeit.

Konzeptionell offene Lücken

Anspruchsvoller sind Punkte, bei denen nicht der Aufwand, sondern eine noch ausstehende inhaltliche Entscheidung der limitierende Faktor ist. Die als "Kontext statt Sitzung" formulierte Idee eines Langzeitgedächtnisses über mehrere Sessions hinweg wirft vor jeder Implementierung die Frage auf, welche Inhalte in welcher Form, für wie lange und mit welcher Einwilligung gespeichert werden dürfen: Eine Abwägung, die eher Datenschutzrecht und Coaching-Ethik betrifft als Softwarearchitektur. Ähnlich verhält es sich mit einem server-seitigen Phasentracking, das dem Sprachmodell die Einschätzung der aktuellen U-Modell-Phase abnehmen würde, und mit der Integration des Methodenkorpus als abrufbare, quellenbelegte Wissensbasis (Retrieval-Augmented Generation) anstelle von Freitext im Systemprompt. In allen drei Fällen bräuchte eine vollumfängliche Lösung in erster Linie mehr Entwicklungszeit, sowie eine sorgfältig hergeleitete Antwort auf eine offene konzeptionelle Frage.

Strukturelle und regulatorische Restfragen

Eine dritte Gruppe von Lücken liegt außerhalb des unmittelbaren Einflussbereichs der Plattform. Die Datenresidenz des eingesetzten Sprachmodells im Voice-Betrieb hängt von den Zusicherungen des Anbieters ab, nicht von *K/COs* eigener Architektur. Die Frage, wie ein Sprachassistent bei längerem Schweigen methodisch

angemessen reagieren sollte, lässt sich nur durch eine eigene empirische Untersuchung mit echten Coachees beantworten - ein Forschungsvorhaben für sich. Auch die regulatorische Einordnung KI-gestützten Coachings insgesamt ist, wie in Kapitel 1 dargestellt, bislang unscharf; der AI Act adressiert Coaching-Systeme nicht explizit.

Governance und Qualitätssicherung im laufenden Betrieb

Die vierte und für eine vollumfängliche Lösung möglicherweise wichtigste Kategorie betrifft die Frage, wie dauerhaft sichergestellt werden könnte, dass die Plattform ihrem eigenen methodischen Anspruch gerecht wird. Der in Kapitel 3.1 beschriebene Grundsatz "Methode vor Modell" gilt aktuell nur so lange, wie die getroffenen Architekturentscheidungen tatsächlich greifen. Es existiert jedoch kein Mechanismus, der über viele Sessions hinweg misst, ob Gespräche methodisch sauber verlaufen, oder der Auffälligkeiten an menschliche Coaches zur Stichprobenprüfung weiterleitet. Ein solcher Rückkopplungsprozess wäre gerade deshalb notwendig, weil der ICF Code of Ethics [9] eine kontinuierliche Qualitätssicherung explizit einfordert - eine Anforderung, der ein einzelner Forschungsprototyp im geschlossenen Teilnehmerkreis nicht in vollem Umfang gerecht werden kann.




Abbildung 1: KiCo - Startseite [KICO — Dein KI-Coach](https://kico.pro)

4. Bewertung des Einsatzes künstlicher Intelligenz im Coaching

Mit der zunehmenden Verbreitung generativer KI-Systeme stellt sich nicht mehr die Frage, ob künstliche Intelligenz im Coaching eingesetzt werden kann, sondern unter welchen Voraussetzungen ihr Einsatz sinnvoll und verantwortungsvoll ist. Während KI-basierte Coachingsysteme zahlreiche Vorteile hinsichtlich Verfügbarkeit, Skalierbarkeit und Kosten bieten, bestehen zugleich Grenzen insbesondere im Bereich zwischenmenschlicher Interaktion, Empathie und ethischer Verantwortung [1][2]. Ziel dieses Kapitels ist es, die Potenziale und Risiken von KI-Coaching wissenschaftlich einzuordnen und dem klassischen Human Coaching gegenüberzustellen. Auf dieser Grundlage wird bewertet, welche Aufgaben zukünftig von KI übernommen werden können und in welchen Bereichen der Mensch weiterhin unverzichtbar bleibt.

4.1 Vergleich menschlicher und KI-basierter Coachingkompetenzen

Um die Einsatzmöglichkeiten künstlicher Intelligenz im Coaching realistisch beurteilen zu können, ist zunächst ein systematischer Vergleich der Fähigkeiten eines menschlichen Coaches und eines KI-basierten Coachingsystems erforderlich. Beide verfolgen grundsätzlich das Ziel, Klientinnen und Klienten bei der Reflexion, Zielerreichung und persönlichen Entwicklung zu unterstützen, unterscheiden sich jedoch erheblich hinsichtlich ihrer Kompetenzen und Wirkungsweise [1][3]. Im Folgenden werden zentrale Coachingkompetenzen gegenübergestellt und hinsichtlich ihrer jeweiligen Stärken und Grenzen bewertet.

Kriterium	Menschlicher Coach	KI-Coach
Empathie	authentisch, emotional	simuliert Empathie
Beziehungsaufbau	Vertrauensbeziehung	funktionale Interaktion
Verfügbarkeit	begrenzt	24/7
Kosten	hoch	sehr gering
Skalierbarkeit	gering	sehr hoch
Individualisierung	intuitiv	datenbasiert
Kreativität	spontan	modellbasiert
Datenschutz	Schweigepflicht	technische und rechtliche Risiken

Tabelle 2: Vergleich menschlicher und KI-basierter Coachingkompetenzen

4.2 Chancen des KI-Coachings

Der Einsatz künstlicher Intelligenz eröffnet neue Möglichkeiten, Coaching einem größeren Personenkreis zugänglich zu machen und Coachingprozesse effizienter zu gestalten. Insbesondere generative KI-Systeme ermöglichen eine zeit- und ortsunabhängige Unterstützung, können große Datenmengen verarbeiten und individuell auf Nutzerbedürfnisse reagieren. Die Forschung zeigt, dass KI insbesondere bei klar definierten Entwicklungszielen positive Effekte erzielen kann und eine hohe Nutzerakzeptanz erreicht [2]. KI-Coaching eröffnet neue Möglichkeiten für die Gestaltung und Durchführung von Coachingprozessen. Zu den wesentlichen Potenzialen zählen:

- permanente Verfügbarkeit
- geringe Kosten
- niederschwelliger Zugang
- hohe Skalierbarkeit
- objektive Strukturierung
- Unterstützung bei Selbstreflexion
- standardisierte Coachingprozesse
- personalisierte Empfehlungen durch Datenanalyse

4.3 Risiken und Grenzen des KI-Coachings

Trotz der technologischen Fortschritte bestehen beim Einsatz künstlicher Intelligenz im Coaching weiterhin erhebliche Herausforderungen. Neben technischen Einschränkungen, wie fehlerhaften oder unzutreffenden Antworten, spielen insbesondere ethische, rechtliche und psychologische Fragestellungen eine zentrale Rolle. Da Coaching auf Vertrauen, Beziehung und individueller Begleitung basiert, stößt KI insbesondere dort an ihre Grenzen, wo menschliche Intuition, emotionale Kompetenz und Verantwortung erforderlich sind. Forschungsarbeiten identifizieren konkrete Risiken: fehlerhafte Kriseninterventionen, unangemessene Bestätigung problematischer Überzeugungen, die Simulation emotionaler Nähe sowie algorithmische Verzerrungen durch Trainingsdaten [5][13]. Der Einsatz von KI im Coaching ist mit verschiedenen fachlichen, ethischen und rechtlichen Risiken verbunden. Diese ergeben sich insbesondere aus den Grenzen der emotionalen und sozialen Interaktion, der möglichen Fehleranfälligkeit von KI-Systemen sowie aus Fragen des Datenschutzes, der Verantwortungszuordnung und des sicheren Umgangs mit sensiblen Situationen.

- eingeschränkte Fähigkeit zu echter Empathie und emotionaler Resonanz
- fehlende zwischenmenschliche Wahrnehmung und nonverbale Interaktion
- fehlerhafte oder frei erfundene Inhalte (Halluzinationen)
- Risiken hinsichtlich Datenschutz und Vertraulichkeit sensibler Coachingdaten

- algorithmische Verzerrungen und diskriminierende Effekte (Bias)
- ungeklärte Verantwortungszuordnung bei fehlerhaften oder schädlichen Empfehlungen
- fehlende menschliche Intuition und situationsbezogenes Erfahrungswissen
- begrenzte Eignung für den Umgang mit psychischen Krisen und akuten Gefährdungssituationen

4.4 Coachingraum, Prozessgestaltung und Verantwortungsübernahme

Ein weiterer wesentlicher Unterschied zwischen menschlichem Coaching und KI-basierten Coachingangeboten liegt in der Gestaltung des Coachingraums und der damit verbundenen Verantwortung für den Coachingprozess. Während ein menschlicher Coach nicht nur Gesprächspartner, sondern zugleich Gestalter des Rahmens und Begleiter des Prozesses ist, findet KI-Coaching überwiegend in einem digitalen und vom Nutzer selbst gesteuerten Umfeld statt. Dadurch verändern sich die Bedingungen, unter denen Verbindlichkeit, Reflexion und Veränderungsprozesse entstehen können.

Im klassischen Präsenzcoaching wird ein klar definierter zeitlicher und räumlicher Rahmen geschaffen. Ein vereinbarter Termin, ein festgelegter Ort und die persönliche Anwesenheit von Coach und Coachee erzeugen eine soziale Verbindlichkeit, die über die reine Gesprächsinformation hinausgeht. Der Coach übernimmt dabei Verantwortung für die Strukturierung und Moderation des Prozesses. Er gestaltet den Gesprächsrahmen, steuert den Einsatz geeigneter Methoden und kann situativ auf das Verhalten, die emotionale Verfassung und die Reaktionen des Coachees eingehen. Dadurch entsteht ein verbindlicher Prozessrahmen, der den Coachee dazu anhalten kann, sich bewusst mit seinen Fragestellungen auseinanderzusetzen.

Bei einem KI-basierten Online-Coaching liegt die unmittelbare Steuerung des Nutzungsprozesses weitgehend beim Coachee. Die Nutzung kann grundsätzlich jederzeit begonnen, unterbrochen oder beendet werden. Ein vereinbarter Termin, eine persönliche Anwesenheitspflicht oder eine soziale Erwartung zur Fortführung des Gesprächs bestehen in der Regel nicht. Ebenso kann der Nutzer die Interaktion

jederzeit verlassen, Themen wechseln oder Antworten abbrechen, ohne dass das System die gleiche Form sozialer Verbindlichkeit herstellen kann wie ein menschlicher Coach. Dies erhöht einerseits die Niedrigschwelligkeit und Autonomie des Angebots, kann andererseits jedoch zu einer geringeren Verbindlichkeit des Coachingprozesses führen.

Darüber hinaus ist Coaching nicht ausschließlich als verbale Interaktion zu verstehen. Insbesondere systemische und erlebnisorientierte Coachingansätze nutzen den physischen Raum als methodisches Element. Visualisierungen, Bodenanker, Karten, Post-its, Gegenstände oder räumliche Anordnungen können dazu eingesetzt werden, Beziehungen, Perspektiven und Zusammenhänge sichtbar und unmittelbar erfahrbar zu machen. Die Veränderung einer räumlichen Anordnung oder die bewusste Einnahme einer anderen Position kann dabei neue Perspektiven auf eine Fragestellung ermöglichen. Auch Farben, Materialien und die haptische Wahrnehmung können Bestandteil solcher Interventionen sein.

Diese Möglichkeiten sind in einem rein sprach-/textbasierten KI-Coaching nur eingeschränkt verfügbar. Zwar können digitale Systeme Visualisierungen, strukturierte Darstellungen oder virtuelle Arbeitsmaterialien bereitstellen, sie ersetzen jedoch nicht vollständig die physische und soziale Erfahrungsdimension eines gemeinsam gestalteten Raumes. Insbesondere die Kombination aus räumlicher Wahrnehmung, körperlicher Positionierung, nonverbaler Kommunikation und unmittelbarer Reaktion des Coaches stellt eine Dimension des Coachings dar, die durch eine rein digitale Interaktion nur begrenzt abgebildet werden kann.

Ein weiterer Unterschied betrifft die Prozessverantwortung. Ein menschlicher Coach kann erkennen, wenn ein Coachee einem Thema ausweicht, sich in Widersprüche verstrickt oder eine vereinbarte Reflexionsaufgabe nicht weiterverfolgt. Er kann diese Beobachtung zum Gegenstand des Coachings machen und den Prozess gezielt unterbrechen oder neu ausrichten. Bei einem KI-System muss ein wesentlicher Teil

dieser Prozesssteuerung durch die technische Gesprächsarchitektur vorgegeben werden. Die Qualität des Coachings hängt damit nicht ausschließlich von der Fähigkeit des Sprachmodells ab, sondern auch von der Gestaltung des Systemprompts, der Gesprächslogik, des Sitzungsmanagements und der definierten Interventionsmechanismen.

Der digitale Coachingraum bietet somit zugleich Chancen und Einschränkungen. Die jederzeitige Verfügbarkeit und hohe Autonomie des Nutzers senken Zugangshürden und ermöglichen eine flexible Nutzung. Gleichzeitig entfallen wesentliche Elemente des physischen und sozialen Rahmens, durch die im menschlichen Coaching Verbindlichkeit, Präsenz und Prozessverantwortung hergestellt werden. Für die Bewertung von KI-Coaching ist daher nicht nur zu betrachten, welche Antworten ein KI-System erzeugen kann, sondern auch, in welchem Rahmen diese Interaktion stattfindet und welche Verantwortung für die Gestaltung und Durchführung des Coachingprozesses übernommen wird.

4.5 Fazit: Hybride Coachingansätze als Zukunftsmodell

Die vorangegangene Betrachtung zeigt, dass künstliche Intelligenz im Coaching erhebliche Potenziale bietet, zugleich jedoch mit spezifischen fachlichen, ethischen und technischen Grenzen verbunden ist. KI-basierte Coachingsysteme ermöglichen insbesondere eine hohe Verfügbarkeit, Skalierbarkeit und einen niederschweligen Zugang zu Coachingangeboten. Sie können Coachingprozesse strukturieren, Reflexionsprozesse unterstützen und auf Basis großer Datenmengen personalisierte Impulse bereitstellen. Diese Vorteile machen KI insbesondere für standardisierbare und niedrighschwellige Coachinganwendungen interessant.

Gleichzeitig zeigen sich deutliche Grenzen in Bereichen, die wesentlich durch die menschliche Beziehung und die situative Gestaltung des Coachingprozesses geprägt sind. Dazu zählen insbesondere authentische Empathie, zwischenmenschliche Resonanz, nonverbale Wahrnehmung, intuitive Situationsbeurteilung sowie die Übernahme von Verantwortung für den Coachingprozess. Auch die Gestaltung eines verbindlichen Coachingraums und der

Einsatz körperlicher, räumlicher und haptischer Methoden lassen sich durch rein digitale Systeme nur eingeschränkt abbilden. KI kann entsprechende Elemente technisch unterstützen oder simulieren, ersetzt jedoch nicht automatisch die soziale und zwischenmenschliche Dimension des Coachings.

Die Gegenüberstellung macht daher deutlich, dass eine Betrachtung von KI und menschlichem Coaching als reine Konkurrenzbeziehung zu kurz greift. Vielmehr weisen beide Ansätze unterschiedliche Stärken auf, die sich in einem hybriden Coachingmodell sinnvoll ergänzen können. KI kann beispielsweise die kontinuierliche Verfügbarkeit, Vorbereitung und Strukturierung von Coachingprozessen unterstützen, während der menschliche Coach insbesondere bei komplexen, emotionalen oder mehrdeutigen Situationen sowie bei der Gestaltung der Beziehung und der Prozessverantwortung eine zentrale Rolle übernimmt.

Hybride Coachingansätze erscheinen vor diesem Hintergrund als ein besonders relevantes Zukunftsmodell. Sie ermöglichen es, die technologischen Möglichkeiten künstlicher Intelligenz mit den sozialen, emotionalen und ethischen Kompetenzen menschlicher Coaches zu verbinden. Dabei sollte KI nicht als Ersatz für den menschlichen Coach verstanden werden, sondern als Werkzeug, das dessen Arbeit ergänzt und neue Formen der Zusammenarbeit zwischen Mensch und Technologie ermöglicht. Die konkrete Ausgestaltung eines solchen Modells muss sich dabei an fachlichen Qualitätsstandards, ethischen Grundsätzen, Datenschutzanforderungen und klar definierten Verantwortlichkeiten orientieren.

Die Entwicklung von KICO stellt einen praktischen Ansatz dar, diese Anforderungen in einem konkreten KI-Coaching-System zu erproben. Die im Rahmen dieser Arbeit entwickelten Anforderungen und Erkenntnisse können dabei als Grundlage für die weitere Entwicklung und Evaluation des Systems dienen. Zugleich bietet die offene Dokumentation und der frei zugängliche Quellcode die Möglichkeit, dass zukünftige Teilnehmerinnen und Teilnehmer der INACCW-Ausbildung das System weiterentwickeln, kritisch überprüfen und um zusätzliche Funktionen und Sicherheitsmechanismen ergänzen.

Selbstständigkeitserklärung

Hiermit erklären wir, dass wir die vorliegende Abschlussarbeit mit dem Titel


“KI im Coaching: Anforderungen an einen KI-Coach und kritische Abwägung gegenüber menschlichem Coaching”

selbstständig und ohne unzulässige fremde Hilfe verfasst haben. Wir haben keine anderen als die angegebenen Quellen benutzt. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder unveröffentlichten Schriften entnommen wurden, sind als solche kenntlich gemacht.


Im Rahmen der Entwicklung der KI-Coachingplattform *KICO* einschließlich der technischen Dokumentation erfolgte eine Unterstützung und ein fachlicher Austausch mit den KI-Systemen *Claude* von Anthropic (<https://www.claude.ai>) und *ChatGPT* von OpenAI.

Die Nutzung generativer KI erfolgte partiell zur Unterstützung bei der Literaturrecherche, zur Identifikation und Einordnung relevanter wissenschaftlicher Quellen, zur Strukturierung von Inhalten sowie zur sprachlichen Überarbeitung einzelner Textpassagen.

Berlin, den 14. September 2026



Henrike Thomsen



Konstantin Escher

Quellenverzeichnis - alphabetische Reihenfolge

[16] BetterUp. (2026). BetterUp AI Coach.

<https://support.betterup.com/hc/en-us/articles/36688702739611-BetterUp-AI-Coach>

[12] Boit, S. & Patil, R. (2025). A prompt engineering framework for large language model-based mental health chatbots: MIND-SAFE. JMIR Mental Health, 12, e75078.

<https://doi.org/10.2196/75078>

[22] Brahmasmi, P. & Bali, D. (2025). Pioneering & designing the world's first coaching-native AI: Principles, challenges, and enterprise applications. Columbia Coaching Conference 2025.

<https://www.columbiacoachingconference.org/post/pioneering-designing-the-world-s-first-coaching-native-ai-principles-challenges-and-enterprise>

[15] CoachHub. (2026). CoachHub – Die digitale Coaching-Plattform.

<https://www.coachhub.com/de>

[4] Cross, S., Collier, A. & Skouteris, H. (2024). Use of AI in mental health care: Community and mental health professionals survey. JMIR Mental Health.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11488652/>

[21] Delenta. (2026). AI in coaching. <https://www.delenta.com/ai-in-coaching>

[7] Deutsche Bundesverband Coaching (DBVC), Standards für Coaching,

<https://www.dbvc.de/standards-fuer/coaching>

[8] Deutschen Gesellschaft für Supervision und Coaching, Ethische Leitlinien,

https://www.dgsv.de/wp-content/uploads/2023/10/DGSv_Ethische-Leitlinien_2023.pdf

[23] European Mentoring and Coaching Council (2015). EMCC COMPETENCE FRAMEWORK V2

<https://www.emccglobal.org/wp-content/uploads/2018/10/EMCC-competences-framework-v2-EN.pdf>

[1] Escher, Thomsen (2026), KiCo - KI-Coaching; KiCo - KI-Coaching Plattform,

<https://kico.pro/>; KiCo GitHub Repository github.com/konnekonnekonne/KI-Coaching

/Verzeichnis docs/

- [6] Europäisches Parlament & Rat der Europäischen Union (2024). Verordnung (EU) 2024/1689 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (AI Act). Amtsblatt der Europäischen Union. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- [9] International Coaching Federation (ICF) (2025), Code of Ethics
<https://coachingfederation.org/wp-content/uploads/2025/03/german-icf-ethics-code-of-ethics-2025.pdf>
- [14] International Coaching Federation (2024). ICF artificial intelligence (AI) coaching framework and standards.
<https://coachingfederation.org/resource/icf-artificial-intelligence-ai-coaching-framework-and-standards/>
- [11] Loughnane, C., Laiti, J., O'Donovan, R. & Dunne, P. J. (2025). Systematic review exploring human, AI, and hybrid health coaching in digital health interventions: Trends, engagement, and lifestyle outcomes. *Frontiers in Digital Health*, 7, 1536416.
<https://doi.org/10.3389/fdgth.2025.1536416>
- [3] McBain, R. K., Bozick, R., Diliberti, M. et al. (2025). Use of generative AI for mental health advice among US adolescents and young adults. *JAMA Network Open*, 8(11), e2542281.
<https://doi.org/10.1001/jamanetworkopen.2025.42281>
- [25] OpenAI. (2025a). Sycophancy in GPT-4o: What happened and what we're doing about it. <https://openai.com/index/sycophancy-in-gpt-4o/>
- [26] OpenAI. (2025b). Expanding on what we missed with sycophancy.
<https://openai.com/index/expanding-on-sycophancy/>
- [10] Passmore, J., Olafsson, B. & Tee, D. (2025). A systematic literature review of artificial intelligence (AI) in coaching: Insights for future research and product development. *Journal of Work-Applied Management*. <https://doi.org/10.1108/JWAM-11-2024-0164>
- [27] Passmore, J. & Tee, D. (2024). AI coaching: Democratising coaching service or offering an illusion? *International Journal of Evidence Based Coaching and Mentoring*.
<https://doi.org/10.1080/17521882.2024.2368598>
- [17] Rocky.ai. (2026). AI coaching platform tailored to your company. <https://www.rocky.ai/>

[2] Rousmaniere, T., Zhang, Y., Li, X., & Shah, S. (2025). Large language models as mental health resources: Patterns of use in the United States. Practice Innovations. Advance online publication. <https://doi.org/10.1037/pri0000292>.

[24a] Scholich, T., Barr, M., Wiltsey Stirman, S., & Raj, S. (2025). A comparison of responses from human therapists and large language model–based chatbots to assess therapeutic communication: Mixed methods study. JMIR Mental Health, 12, e69709. <https://doi.org/10.2196/69709>

[5] ScienceDaily / Brown University (2026). ChatGPT as a therapist? New study reveals serious ethical risks. <https://www.sciencedaily.com/releases/2026/03/260302030642.htm>

[18] Sherlock Performance AI. (2026). Sherlock AI. <https://www.sherlockperformance.com/>

[13] Suhas BN, Sherrill, A. M., Arriaga, R. I., Wiese, C. W. & Abdullah, S. (2026). AI safety training can be clinically harmful. arXiv preprint arXiv:2604.23445. <https://arxiv.org/html/2604.23445>

[24b] Wei, M. (2025). New studies reveal mental health blindspots of AI chatbots. Psychology Today. <https://www.psychologytoday.com/us/blog/urban-survival/202510/new-studies-reveal-mental-health-blindspots-of-ai-chatbots>

[20] Woebot Health. (2026). Woebot Health. <https://woebothealth.com/>

[19] Wysa. (2026). Wysa – Everyday mental health. <https://www.wysa.com/>